

SPRAWOZDANIE

Grupa 3

Wykonali:

Szymon Ciura

Tomasz Jaśkowiec

Szymon Dziedzina

07.2025 Kraków

Wstęp

Celem projektu jest analiza zmienności zasięgu lodu morskiego wokół Antarktydy. Analiza obejmuje dane z lat 1978 do 2009. W ramach analizy wyznaczono kontur przedstawiający minimalny zasięg lodu morskiego w badanym okresie, dla wszystkich kątów, co pozwala na przybliżenie rzeczywistego kształtu obszaru okołobiegunowego.

Następnie dla każdego kąta z osobna opracowano model matematyczny opisujący zmienność zasięgu lodu w funkcji czasu, z uwzględnieniem specyfiki danych (również tego że danych może brakować) i nieregularności pojawiania się lodu.

Kończącym elementem projektu była wizualizacja zmian zasięgu lodu morskiego w formie animacji. Animacja przedstawia zarówno rzeczywisty zasięg lodu w kolejnych dniach, jak i jego modelowaną wartość, umożliwiając obserwację zmian sezonowych i długoterminowych. Zaproponowany został również model biorący pod uwagę wszystkie dane.

Dane

Dane użyte do projektu znajdują się w pliku `daily_ice_edge.csv`. Plik zawiera informacje dotyczące zasięgu lodu morskiego wokół Antarktydy, zebrane dla 360 kątów odpowiadających długości geograficznej. Informacje przedstawiają promień oddalenia od środka bieguna i obejmują długi okres czasowy, od 26 października 1978 roku do 16 maja 2009 roku, co pozwala na analizę zmian zasięgu lodu morskiego w ujęciu wieloletnim.

Wykonanie

Całość kodu użyta do zobrazowania danych oraz animacji znajduje się na repozytorium GitHub pod adresem:

[Repozytorium](#)

Część 0) Narysowanie konturu minimalnego zasięgu lodu

Wczytanie danych:

```
df = pd.read_csv('daily_ice_edge.csv')
```

Abyśmy mogli odpowiednio „narysować” kontur minimalnego zasięgu lodu, należało przekształcić podane dane tak by można było je zaprezentować w biegunowym układzie.

Model minimalnego zasięgu wymaga od nas użycia poniższego kodu:

```
18
19
20 minimum = [df[col].min() for col in df.columns[1:]]
```

Takie dane wymagają normalizacji, tak by kształt modelu oddał najbliższe przybliżenie rzeczywistego terenu.

Tworzymy do tego celu odpowiednią funkcję normalizującą:

```
def normalize_range(data, new_min, new_max):
    old_min = min(data)
    old_max = max(data)
    return [(x - old_min) / (old_max - old_min) * (new_max - new_min) + new_min for x in data]
```

Która jest rozszerzoną wersją normalizacji min-max o formule:

$$x_{\text{norm}} = \frac{x - \min(x)}{\max(x) - \min(x)} \cdot (\text{new_max} - \text{new_min}) + \text{new_min}$$

Generujemy kąty:

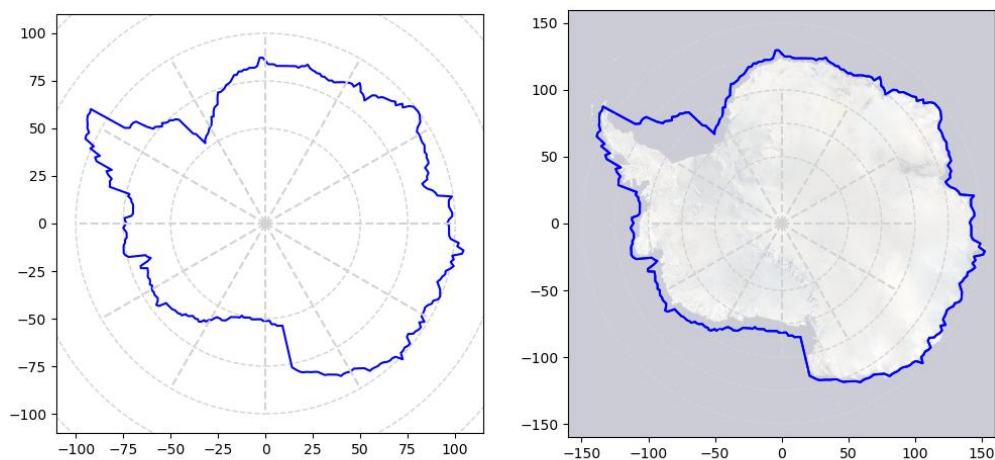
```
angles = np.linspace(start=0, stop=360, len(minimum), endpoint=False)
angles=(angles)%360
```

Przekształcamy dane z formatu biegunowego na współrzędne kartezjańskie:

```
punkty = []
for angle, radius in zip(angles, minimum_normalized):
    x = math.sin(math.radians(angle)) * radius
    y = math.cos(math.radians(angle)) * radius
    punkty.append((x, y))
```

Następnie tworzymy wykres, który przedstawia minimalny zasięg lodu:

model minimalnego zasięgu lodu dla wszystkich kątów



Wymodelowany zasięg lodu z prawej strony został nałożony na mapę w projekcji ortograficznej, opartą na zestawie danych Blue Marble opracowanym przez NASA

https://en.wikipedia.org/wiki/File:Antarctica_6400px_from_Blue_Marble.jpg

Część 1) Model matematyczny zasięgu lodu w funkcji czasu

By zautomatyzować znalezienie funkcji optymalnej dla każdego wierzchołka użyjemy funkcji **curve_fit**, która przy podanych współczynnikach znajduje najlepiej dopasowane parametry funkcji podanej w modelu

```
def sinusoid(t, A, omega, phi, C):  
    return A * np.sin(omega * t + phi) + C
```

Dla każdego kąta podstawiane są odpowiednie dane: t (czas, z którego pochodzi kąt) oraz y (wartość danego kąta). Proces ten realizowany jest w pętli, co umożliwia obliczenia dla kolejnych kątów.

Znalezienie funkcji, opiera się na zgadnięciu początkowych wartości zawartych w liście **guess**

```
for col in tqdm(df_numeric.columns):  
    y = df_numeric[col].values  
  
    try:  
        guess = [np.std(y), 2 * np.pi / len(y), 0, np.mean(y)]  
        popt, _ = curve_fit(sinusoid, t, y, p0=guess, maxfev=100000)  
        A, omega, phi, C = popt  
  
        A_ = round(A, 8)  
        omega_ = round(omega, 8)  
        phi_ = round(phi, 8)  
        C_ = round(C, 8)  
  
        funkcja_str = f"lambda x: {A_} * sin({omega_} * x + {phi_}) + {C_}"  
    except Exception:  
        funkcja_str = "None"
```

Która kolejno zawiera:

- Amplitudę (parametr A) – wyliczana na podstawie odchylenia standardowego (wielkości zmian)
- Omega- obliczona na podstawie założenia że cykl trwa całą długość danych
- Phi – przesunięcie w czasie(w tym przypadku 0)
- C – średnia wartość danych (liczona na podstawie średniej)

Na podstawie tych danych funkcja `curve_fit` dopasowuje najlepsze możliwe parametry, tak aby wynikowa funkcja sinusoidalna zależna od t i y najlepiej odwzorowywała dane. Parametr `p0` wskazuje, że dopasowanie powinno rozpocząć się od wartości z listy `guess`, natomiast `maxfev` określa maksymalną liczbę prób dopasowania. Wynikiem działania funkcji jest zmienna `popt`.

Wynik ten przypisywany jest jako tekst (string) do funkcji `lambda`, co umożliwia późniejszy eksport do osobnego DataFrame'a. Finalnie, DataFrame ten zawiera — dla każdego kąta od 0 do 360 stopni — odpowiednio dopasowaną funkcję wyznaczoną na podstawie powyższych obliczeń.

```
popt, _ = curve_fit(sinusoid, t, y, p0=guess, maxfev=10000)
A, omega, phi, C = popt

A_ = round(A, 8)
omega_ = round(omega, 8)
phi_ = round(phi, 8)
C_ = round(C, 8)
```

Oto przykładowy wynik:

wierzcholek	lambda_funkcja
longitude_0E	lambda x: -0.29129447 * sin(0.00047897 * x + 0.90424355) + -62.50054478
longitude_1E	lambda x: -0.28349888 * sin(0.00047276 * x + 0.84410672) + -62.58995801
longitude_2E	lambda x: -0.28825549 * sin(0.00045919 * x + 0.77888505) + -62.58431987
longitude_3E	lambda x: -0.27761473 * sin(0.00046156 * x + 0.73627581) + -62.56683344
longitude_4E	lambda x: -0.2620355 * sin(0.00045654 * x + 0.76953585) + -62.58166678
longitude_5E	lambda x: -0.25839012 * sin(0.00045458 * x + 0.78396742) + -62.54431808
longitude_6E	lambda x: -0.25429779 * sin(0.00048417 * x + 0.62650072) + -62.50588588
longitude_7E	lambda x: -0.24494354 * sin(0.00048886 * x + 0.56635734) + -62.44656687
longitude_8E	lambda x: -0.23670056 * sin(0.00052472 * x + 0.46103368) + -62.40224811
longitude_9E	lambda x: -0.25958268 * sin(0.00051781 * x + 0.55348207) + -62.33048228
longitude_10E	lambda x: -0.24693171 * sin(0.00049334 * x + 0.58817137) + -62.23803966
longitude_11E	lambda x: -0.25174867 * sin(0.00044658 * x + 0.78440864) + -62.15348098
longitude_12E	lambda x: -0.2443874 * sin(0.00041228 * x + 0.90518902) + -62.10871006
longitude_13E	lambda x: -0.28075989 * sin(0.00029638 * x + 1.29667801) + -62.06270938
longitude_14E	lambda x: -3.12535305 * sin(5.34e-05 * x + 1.70913584) + -59.34984094
longitude_15F	lambda x: -1.3531636 * sin(0.00010192 * x + 1.53320864) + -61.08940132

Część 2) Animacja

W ramach tego podpunktu przygotowano animację obrazującą zmiany zasięgu lodu morskiego w czasie na podstawie danych z pliku. Działając na kodzie bazowym z podpunktu 0 uzyskano podstawę do wykonania animacji.

W pierwszej kolejności za pomocą list dla współrzędnych x i y pochodzącej z wcześniej przedstawionej listy punktów tworzymy obiekt **Polygon** i za pomocą funkcji **.add_patch** dodajemy wcześniej już uzyskany kształt minimalnego zasięgu lodu jako stały element.

```
points = list(zip(xm, ym))
granica = Polygon(points, closed=True, facecolor='none', edgecolor='red', alpha=0.5)
ax.add_patch(granica)
```

Następnie tworzymy funkcję update w której definiujemy zasady tworzenia kolejnych klatek obrazujących zmierzony zasięg lodu w kolejnych dniach. Dodatkowo dla dopełnienia danych przedstawianych na animacji dodajemy tytuł informujący o dniu w którym dana klatka -przedstawiająca zasięg lodu został zmierzony.

```
def update(frame):
    row = df.iloc[frame, 1:]
    normalized = normalize_range(row, radii_min, radii_max)
    xs = [math.sin(math.radians(a)) * r for a, r in zip(angles, normalized)]
    ys = [math.cos(math.radians(a)) * r for a, r in zip(angles, normalized)]
    xs.append(xs[0])
    ys.append(ys[0])
    line.set_data(xs, ys)
    title.set_text(f"Zasięg lodu - dzień {df.iloc[frame, 0]}")
    return line, title

# Stwórz animację
ani = animation.FuncAnimation(fig, update, frames=len(df), interval=100, blit=False)

plt.show()
```

Na koniec tworzymy animację i wywołujemy całość. Końcową wersję animacji można zobaczyć w załączonym pliku. Niebieska linia przedstawia granicę zmierzonego zasięgu lodu danego dnia a czerwona jego minimalną wartość.

Część 2) Model zasięgu lodu biorący pod uwagę wszystkie dane na raz

Aby stworzyć model zasięgu lodu biorący pod uwagę wszystkie dane czyli $f(\text{Lat}, \text{Lon}, t)$ – szerokość geograficzną (Lat), długość geograficzną (Lon) oraz czas (t), możemy założyć, że w trakcie każdego roku występuje podobny cykl zasięgu występowania. Rozkład lodu po długości geograficznej i szerokości jest mniej więcej regularny a więc moglibyśmy to modelować za pomocą sinusoidy. Należy do tego dodatkowo uwzględnić dzień dla którego modelujemy dane, czyli również jest to wartość dla której możemy brać pod uwagę dane z lat poprzednich. Pozwoliło by to nam otrzymać zasięg lodu dla podanych parametrów, a więc również przewidywać ich wartości.

Podsumowanie

Opracowanych dane zasięgu lodu morskiego na Antarktydzie na przestrzeni lat obrazują zmienność tego zjawiska. Opracowane dane pozwoliły otrzymać pełny obraz zmienności tego zasięgu w czasie. Przygotowano kontur minimalnego zasięgu lodu, który pozwolił ukazać przybliżony kształt rzeczywistego obszaru polarnego. Dla każdego kąta geograficznego wyznaczono model matematyczny opisujący zmiany zasięgu lodu w funkcji czasu, czego wyniki zostały zapisane do pliku. Modele te uwzględniają sezonowe fluktuacje oraz nieciągłości w danych wynikające z braku lodu w niektórych okresach. Przygotowano animację, która w przejrzysty sposób ilustruje zmiany zasięgu lodu. Zaproponowano również model biorący pod uwagę wszystkie dane. Przedstawiona analiza pozwala na lepsze zrozumienie dynamiki zjawisk zachodzących w rejonie Antarktydy oraz stanowi dobrą podstawę do dalszych, bardziej zaawansowanych badań w tym obszarze, na przykład wpływowi globalnego ocieplania na występowanie lodu.